



Python_Learning

Curso Online de Python para Biólogos



INSTRUCTOR

Felipe Gómez

FECHA Y HORA

**Martes 01 de
septiembre**

11:30 am

SESIÓN 3

**Análisis
estadístico**



Ministerio de
Ciencia,
Tecnología,
Conocimiento
e Innovación

Gobierno de Chile

ANID
Agencia
Nacional de
Investigación
y Desarrollo

Gobierno de Chile

Python_Learning

Clase 3: Análisis estadístico




Estadística descriptiva con `numpy` y `scipy`.

Resumir, visualizar y reconocer la variabilidad de los datos.



Comparaciones entre tratamientos: `t-test`, `ANOVA`.

De una pregunta biológica a `t-test`, `ANOVA` y comparaciones post-hoc.



Ajuste no lineal: `crecimiento logístico (curve_fit)`.

Describir una curva de crecimiento con un modelo logístico.

Python_Learning

Clase 3: Análisis estadístico




Estadística descriptiva con **numpy** y **scipy**.

Resumir, visualizar y reconocer la variabilidad de los datos.



Comparaciones entre tratamientos: **t-test**, **ANOVA**.

De una pregunta biológica a t-test, ANOVA y comparaciones post-hoc.




Ajuste no lineal: **crecimiento logístico (curve_fit)**.

Describir una curva de crecimiento con un modelo logístico.

Estadística descriptiva


- La estadística descriptiva organiza, resume y visualiza los datos observados.
- No intenta todavía generalizar a toda una población: primero nos ayuda a entender qué tenemos.

Explorar → resumir → visualizar → detectar problemas



Tendencia central: ¿dónde está el centro?

- Media: centro aritmético. Usa todos los valores, por eso un dato extremo puede desplazarla.
- Mediana: valor central después de ordenar los datos. Suele ser más robusta frente a asimetría y outliers.



$$\bar{x} = (1/n) \cdot \sum x_i$$


Ejemplo: 10, 11, 12, 13, 40 → media = 17,2; mediana = 12

Dispersión: ¿cuánto varían los datos?

- Desviación estándar (SD): cuantifica la distancia típica de las observaciones respecto de la media. Tiene las mismas unidades que la variable.
- IQR: ancho del 50% central de los datos. Es menos sensible a valores extremos.


$$s = \sqrt{[\Sigma(x_i - \bar{x})^2 / (n - 1)]}$$

$$\text{IQR} = Q_3 - Q_1$$



Antes del test: visualice los datos

- **Histograma:** forma general, asimetría y posibles colas.
- **Boxplot:** mediana, IQR, dispersión y valores extremos.
- **Scatterplot:** relación entre variables y patrones no lineales.



Regla práctica: no elija un test “a ciegas” sólo porque una función existe en SciPy.

Python_Learning

Clase 3: Análisis estadístico




Estadística descriptiva con **numpy** y **scipy**.

Resumir, visualizar y reconocer la variabilidad de los datos.



Comparaciones entre tratamientos: **t-test**, **ANOVA**.

De una pregunta biológica a t-test, ANOVA y comparaciones post-hoc.



Ajuste no lineal: **crecimiento logístico (curve_fit)**.

Describir una curva de crecimiento con un modelo logístico.

De describir a inferir

Estadística descriptiva

“En mis 8 plantas tratadas, la media fue 19.0 cm.”


Inferencia estadística

“El tratamiento aplicado sugiere una mejora en el crecimiento de las plantas”

La inferencia intenta aprender sobre una población utilizando una muestra.

Primero: ¿cuál es la unidad experimental?

Ejemplo: 3 plantas por tratamiento y 10 hojas medidas por planta.



30 hojas $\neq$ 30 réplicas biológicas independientes

En este diseño, el n biológico principal es 3 plantas por grupo.

Hipótesis nula y alternativa

H₀ — hipótesis nula

No hay diferencia en la media poblacional.

$$\mu_{\text{control}} = \mu_{\text{tratamiento}}$$


H₁ — hipótesis alternativa

Existe una diferencia en la media poblacional.

$$\mu_{\text{control}} \neq \mu_{\text{tratamiento}}$$

El test pregunta: “si H₀ fuera cierta, ¿qué tan compatible es nuestro resultado con ese escenario?”

¿Qué significa el p-value?



$$p = P(|T| \geq |t_{\text{obs}}| \mid H_0)$$

$\alpha = 0,05$ es un umbral de decisión: $p < \alpha$ aporta evidencia contra H_0 ; no convierte el resultado en “verdadero” o “falso”.

Interpretación

Probabilidad, bajo H_0 , de observar un resultado tan extremo o más que el observado.

NO significa

“probabilidad de que H_0 sea verdadera” ni “probabilidad de que mi hipótesis sea correcta”.

Significancia estadística $\neq$ relevancia biológica

Caso A: n enorme

Control = 20.00 cm

Tratamiento = 20.05 cm

$p < 0.000001$

Significativo, pero ¿0.05 cm importa biológicamente?

Caso B: n pequeño

Control = 20 cm

Tratamiento = 30 cm


$p = 0.07$

No cruza 0.05, pero el posible efecto puede justificar más experimentación.

Reporte ideal = p-value + tamaño del efecto + incertidumbre + contexto biológico

Selección de pruebas: ¿qué test necesito?

Guía rápida para elegir una prueba de comparación de grupos



Welch t-test: una diferencia medida en unidades de incertidumbre

$$t = (\bar{x}_1 - \bar{x}_2) / \sqrt{(s_1^2/n_1 + s_2^2/n_2)}$$

Numerador

$$\bar{x}_1 - \bar{x}_2$$

La diferencia observada entre las medias.

Denominador


Error estándar. Resume cuánto puede fluctuar esa diferencia por muestreo.

|t|

Crece cuando la diferencia es grande respecto de su incertidumbre.

Idea clave: el t-test no pregunta sólo “¿son distintas las medias?”, sino “¿la diferencia es grande comparada con el ruido esperado?”.

Welch t-test en Python



```
from scipy import stats


res = stats.ttest_ind(
    control,
    tratamiento,
    equal_var=False
)

print(res.statistic)
print(res.pvalue)
```

Interpretación: primero la pregunta y el diseño; después el p-value.

API: SciPy 1.18 — `scipy.stats.ttest_ind`.

ANOVA: la intuición



**F = variación
ENTRE grupos /
variación DENTRO
de grupos**

- F cercano a 1 → los grupos no se separan mucho respecto a su variabilidad interna.
- F grande → la separación entre medias es grande respecto al ruido interno.

NIST one-way ANOVA: F compara mean square de tratamientos con mean square del error.

ANOVA: cómo se construye el estadístico F

$$SS_{total} = SS_{entre} + SS_{dentro} \quad \cdot \quad F = MS_{entre} / MS_{dentro}$$

Variación entre grupos

$SS_{entre} = \sum n_i (\bar{x}_i - \bar{x})^2$
Cuánto se aleja cada media grupal de la media global.

Variación dentro


$SS_{dentro} = \sum \sum (x_{ij} - \bar{x}_i)^2$
Cuánto se dispersan los datos alrededor de su propia media.

Mean squares

$MS = SS / \text{grados de libertad}$
El cociente entre ambos produce F.

No es necesario memorizar las sumas: importa entender que ANOVA compara separación entre grupos con variación interna.

ANOVA de una vía en Python



```
from scipy import stats

res = stats.f_oneway(
    control,
    fert_a,
    fert_b
)

print(res.statistic) # F
print(res.pvalue)
```

$H_0: \mu_{\text{control}} = \mu_A = \mu_B$ | H_1 : al menos una media difiere

SciPy: `scipy.stats.f_oneway`; `equal_var=False` permite Welch ANOVA en versiones actuales.

Tukey HSD: comparaciones post-hoc

```
res = stats.tukey_hsd(  
    control,  
    fert_a,  
    fert_b  
)  
  
print(res)
```

Control vs A

$p < 0.05 \rightarrow$ diferentes

Control vs B

$p < 0.05 \rightarrow$ diferentes

A vs B

$p < 0.05 \rightarrow$ diferentes

Tukey controla la tasa de error familiar al evaluar todas las comparaciones por pares.

Python_Learning

Clase 3: Análisis estadístico



Estadística descriptiva con `numpy` y `scipy`.

Resumir, visualizar y reconocer la variabilidad de los datos.



Comparaciones entre tratamientos: `t-test`, `ANOVA`.

De una pregunta biológica a t-test, ANOVA y comparaciones post-hoc.



Ajuste no lineal: `crecimiento logístico (curve_fit)`.

Describir una curva de crecimiento con un modelo logístico.

Ajuste no lineal: otra pregunta estadística

Comparar tratamientos

¿Los grupos difieren?
→ t-test / ANOVA

Describir una relación

¿Qué función describe cómo cambia y con x?
→ ajuste de curvas

Ahora la pregunta no es “¿difieren las medias?”, sino “¿qué parámetros describen la dinámica?”

Ajustar una curva: datos, residuos y mínimos cuadrados

$$r_i = y_i - f(x_i, \theta) \rightarrow \theta = \arg \min \sum r_i^2$$

Dato observado

y_i
Lo que realmente
medimos en el
experimento.

Predicción

$f(x_i, \theta)$
Lo que predice la curva
para un conjunto de
parámetros θ .

Residuo

r_i
La distancia vertical entre
el dato y la curva.

curve_fit busca los parámetros que hacen pequeña la suma de residuos al cuadrado. “Ajustar” no significa que el modelo sea verdadero.

Modelo logístico de crecimiento

$$y(t) = K / [1 + \exp(-r(t-t_0))]$$

K

Asíntota o máximo predicho. Misma unidad que y.

r


Controla la rapidez del cambio. Unidades aproximadas: 1/tiempo.

t₀

Ubica la transición en el tiempo. En este modelo $y(t_0)=K/2$.

La fórmula comprime una dinámica completa en tres parámetros interpretables biológicamente.

Ajustar el modelo logístico en Python



```
from scipy.optimize import curve_fit

def logistica(t, K, r, t0):
    return K/(1 + np.exp(-r*(t-t0)))

popt, pcov = curve_fit(
    logistica, tiempo, biomasa,
    p0=[35, 0.25, 15]
)

K, r, t0 = pop
```

SciPy 1.18: `scipy.optimize.curve_fit(f, xdata, ydata, p0=...)`.

Ejemplo integrador

Un experimento mide biomasa final en tres tratamientos y, además, registra el crecimiento temporal del tratamiento B.

1. Describir

Media, SD, boxplot por tratamiento.

2. Comparar

ANOVA: ¿alguna media difiere?

3. Localizar

Tukey: ¿qué pares difieren?

4. Modelar

Logístico

5. Interpretar

resultado + contexto biológico

Flujo de análisis del ejercicio



El código ejecuta el análisis; el razonamiento decide si ese análisis responde la pregunta.

Mapa de decisión rápido

¿Cuál es mi pregunta?

2 grupos

independientes → Welch t
pareados → material
complementario

3+ grupos

ANOVA → post-hoc

Relación continua

curve_fit / modelo

Siempre antes: unidad experimental + visualización + supuestos

Cinco ideas para llevarse de la clase

1. Describir y visualizar viene antes de inferir.
2. El p-value no es la probabilidad de que H_0 sea verdadera.
3. La unidad experimental determina qué observaciones son independientes.
4. ANOVA significativo no dice qué pares difieren: use post-hoc.
5. Un modelo no lineal debe ajustar los datos y tener sentido biológico.



Python_Learning

Curso Online de Python para Biólogos



INSTRUCTOR

Felipe Gómez

FECHA Y HORA

**Martes 01 de
septiembre**

11:30 am

SESIÓN 3

**Análisis
estadístico**



Ministerio de
Ciencia,
Tecnología,
Conocimiento
e Innovación

Gobierno de Chile

ANID
Agencia
Nacional de
Investigación
y Desarrollo

Gobierno de Chile